Thinking...

> **Evaluating diagnostic strategy**
>
> I'm formulating an overall diagnosis: we need major revisions. There are key concerns to address, including dataset transparency, generalization issues, and inconsistent benchmarks. An action plan is emerging: first, I'll conduct a data audit to assess raw data for duplicates and missingness, clarifying whether the model is multitask or separate. Next, I'll manage a splitting approach. Finally, I'll ensure benchmarks are consistent across datasets, considering alternatives if necessary. Let's dive into this!
>
> **Addressing uncertainty and ablation**
>
> I'm thinking about how to handle uncertainty in my analysis. For each fold, I need to calculate the mean and standard deviation, using out-of-fold metrics like MAE, RMSE, and R^2 along with bootstrap confidence intervals. I might conduct paired tests and consider prediction intervals as optional. For ablation studies, I'll compare the full model versus versions with modules removed, reporting changes in MAE and their significance. I should also interpret any density exceptions carefully. There's a lot to manage here!

可以。综合两位审稿人的意见，这次修稿应当按一次**系统性的大修（Major Revision）**来处理。两位审稿人的核心关注基本一致，不需要分别做两套实验，而是建立一套统一、无泄漏、可复现的验证流程，然后用这套结果同时回复两位审稿人。

一、两位审稿人意见的整合总结

两位审稿人的意见可以归纳为以下七个核心问题。

1. 数据集构成和融合过程不透明

审稿人希望明确知道：

- 原始数据一共有多少条；
- 一共有多少个独立聚合物；
- 每个目标性质分别有多少有效标签；
- primary dataset 和 supplementary datasets 之间有多少重叠；
- 重复结构如何处理；
- 缺失标签如何处理；
- SMILES augmentation 后增加的是序列数量，还是独立聚合物数量；
- 五种性质是否来自同一批聚合物；
- 文章到底是单个多任务模型，还是五个独立的单性质模型。

目前这些信息不够清楚，因此审稿人无法判断结果是否可靠。

---

2. 可能存在数据泄漏，当前五折交叉验证不够可信

这是两位审稿人最重要的共同质疑之一。

主要风险包括：

- 同一聚合物可能存在多个 SMILES；
- randomized/augmented SMILES 可能跨训练集和验证集；
- primary 和 supplementary datasets 中可能存在相同聚合物；
- 同一重复单元可能因为书写方向不同而被识别成不同样本；
- 高度相似的聚合物可能被随机分到训练集和验证集；
- 数据标准化、特征缩放或超参数选择可能使用了验证集信息。

因此，仅写“采用随机五折交叉验证”是不够的。必须证明：

> 同一个聚合物的所有表示都只能出现在同一个 fold 中，而且增强只能在划分完成后对训练集进行。

---

3. Table 1 和 Table 2 的结果严重不一致

最明显的问题是：

- Table 1 中 T_g MAE 为 53.39 K；
- Table 2 中却报告为 4.02 K。

两个数相差一个数量级。如果不解释清楚，会直接影响整篇文章的可信度。

审稿人要求明确：

- 是否来自不同数据集；
- 是否使用不同划分；
- 是否一个是训练集结果、一个是测试集结果；
- 是否使用了不同单位；
- 是否忘记进行 inverse transformation；
- 是否来自不同版本的模型；
- 是否存在代码或表格录入错误；
- 是否存在数据重叠或泄漏。

---

4. “State-of-the-art”结论缺少公平比较基础

如果不同文献使用的是：

- 不同数据集；
- 不同目标定义；
- 不同数据清洗；
- 不同训练/测试划分；
- 不同单位；
- 不同评价指标；
- 不同实验或模拟条件；

那么不能把这些 MAE 直接放在一起排名，也不能据此宣称“new state-of-the-art”。

两位审稿人都希望你：

- 在同一数据、同一 folds、同一评价协议下重新运行基线；
- 或者删除 SOTA 声明，把文献结果改成定性参考。

---

5. 缺少不确定性、统计显著性和可靠的消融解释

目前如果只报告一个平均 MAE，就不能证明模型稳定。

审稿人希望看到：

- 每个 fold 的结果；
- mean ± standard deviation；
- confidence interval；
- 不同随机种子的稳定性；
- 消融模型和完整模型之间是否存在统计显著差异；
- 某个模块是否在所有性质上都有效；
- 对“不符合预期”的消融结果进行诚实解释。

例如，如果去掉 CNN 后 density 的结果反而更好，就不能继续写“CNN 对所有性质均有稳定贡献”。

---

6. MolFormer 的领域迁移和输入表示存在局限

MolFormer 主要基于通用分子或小分子语料预训练，而论文研究的是聚合物。审稿人质疑：

- 小分子预训练表示是否真的适合聚合物；
- 性能提升是否来自预训练；
- polymer-specific model 是否可能更好；
- 是否应该和 polyBERT、PolyNC 等聚合物模型比较。

同时，repeat-unit SMILES 和手工 backbone/side-chain descriptors 无法描述：

- 分子量；
- 聚合度；
- 分子量分布；
- tacticity；
- 支化和交联；
- 链构象；
- 结晶度；
- 缠结；
- 三维堆积；
- 加工历史；
- 温度、压力和测试条件。

因此，文章需要更谨慎地解释模型能预测什么、不能预测什么。

---

7. 文献引用需要筛选，不能机械加入

审稿人推荐的文章中：

- 导电聚合物生物电极文章：可用于说明功能聚合物和多尺度结构的重要性；
- HTPB 固体推进剂蠕变文章：可用于说明宏观性质受微结构、载荷条件和加工状态影响；
- geopolymer recycled aggregate 文章：与有机聚合物 SMILES 性质预测关系较弱，可以礼貌说明未采用。

二、总体修订原则

这次修订建议遵循以下原则：

> **先审计数据，再重新划分，再重新训练，最后重新生成所有表格和结论。**

不能只修改文字，因为现在的问题涉及：

- 数据组成；
- 数据划分；
- 模型评价；
- 表格数值；
- SOTA 声明；
- 消融结论。

推荐的正确流程是：

```
原始数据审计
→ 结构标准化
→ 重复结构识别
→ primary/supplementary 数据融合
→ 冲突标签处理
→ 分配 polymer group ID
→ 按 group/cluster 进行五折划分
→ 在每个训练 fold 内进行特征标准化
→ 只对训练集进行 SMILES augmentation
→ 重新训练所有模型
→ 生成 out-of-fold predictions
→ 在原始物理单位上计算指标
→ 统计不确定性和显著性
→ 重写结果、讨论和结论
```

三、具体需要修改的内容及修改方法

A. 数据集部分

A1. 建立完整的数据审计表

需要统计

对每个数据源分别统计：

1. 原始数据行数；
2. 可成功解析的 SMILES 数；
3. 无效 SMILES 数；
4. canonicalization 前的结构数；
5. canonicalization 后的 unique polymers 数；
6. 重复结构数；
7. 每个性质的有效标签数；
8. 每个性质的缺失标签数；
9. primary 和 supplementary datasets 的重叠数；
10. 数据融合后最终的独立聚合物数；
11. augmentation 后的训练序列数。

建议增加表格

Table S1. Dataset composition

Dataset	Raw rows	Valid structures	Unique polymers	Duplicates removed	T_g	T_c	FFV	Density	R_g
Primary dataset									
Supplementary dataset 1									
Supplementary dataset 2									
Final merged dataset									

特别注意

必须明确区分：

- **raw records**；
- **unique polymers**；
- **property labels**；
- **augmented SMILES sequences**。

不能把 augmentation 产生的多个 SMILES 当成新的独立聚合物。

A2. 报告不同性质标签的重叠情况

需要说明：

- 有多少聚合物只有一个性质标签；
- 有多少同时具有两个、三个、四个、五个标签；
- 五个性质是否使用相同样本；
- 每个性质的训练样本量是否不同。

建议增加

- UpSet plot；
- property availability heatmap；
- 补充材料中的标签重叠矩阵。

例如：

Property pair	Number of shared polymers
T_g and T_c	
T_g and FFV	
T_g and density	
FFV and density	
Density and R_g	

A3. 明确 primary 和 supplementary datasets 的融合规则

必须说明：

- supplementary dataset 中的重叠结构是删除、合并还是补全标签；
- 同一结构存在多个实验值时怎么处理；
- 是否取平均值、中位数或保留多条记录；
- 如果相同聚合物的标签冲突，如何处理；
- 单位是否统一；
- 温度、压力、模拟条件是否统一；
- 是否优先采用某一个数据源。

建议在 Methods 中增加：

> Dataset Integration and Duplicate Resolution

需要给出清晰规则，例如：

```
相同 canonical polymer identity + 相同目标性质
→ 检查单位和实验条件
→ 若条件相同，取平均值/中位数
→ 若条件不同，保留条件信息或排除不可比较记录
```

不能在没有说明测试条件的情况下，直接把不同来源的标签平均。

A4. 明确是多任务模型还是五个独立模型

这是必须澄清的问题。

如果是五个独立模型

建议写：

> Five property-specific models sharing the same general architecture were trained separately for the five target properties.

同时删除或修改：

- simultaneous prediction；
- unified multitask prediction；
- single model for five properties。

如果是真正的多任务模型

必须说明：

- 输出层是否为5维；
- 缺失标签如何 mask；
- loss 如何计算；
- 各任务权重；
- 每个 batch 如何处理不同标签；
- target-specific descriptors 如何进入统一模型；
- 最终结果是一个模型还是五个模型。

B. 数据泄漏与交叉验证

B1. 在数据划分前完成结构标准化

正确顺序必须是：

```
SMILES parsing
→ repeat-unit standardization
→ connection-point normalization
→ canonicalization
→ duplicate detection
→ polymer group assignment
→ cross-validation split
→ augmentation
```

不能先增强再划分。

B2. 给每个独立聚合物分配 group ID

建议建立：

```
polymer_group_id
```

相同聚合物的以下所有记录必须使用同一个 group ID：

- canonical SMILES；
- randomized SMILES；
- 反向书写的 repeat-unit SMILES；
- primary dataset 中的记录；
- supplementary dataset 中的记录；
- 同一个结构的多个标签记录；
- augmentation 产生的所有序列。

然后使用：

- GroupKFold；
- StratifiedGroupKFold，若适合连续目标分箱；
- 自定义 group-level split。

基本要求：

> 同一 group 不能同时出现在训练 fold 和验证 fold。

B3. SMILES augmentation 必须在划分之后进行

正确流程：

```
Original unique polymers
→ assign folds
→ select training polymers
→ augment training SMILES only
→ train model
→ evaluate on original validation SMILES
```

不正确流程：

```
All polymers
→ augment all SMILES
→ randomly split augmented sequences
```

验证集应使用：

- 标准化 canonical representation；
- 或提前规定的单一、非增强表示。

如果使用 test-time augmentation，也必须单独说明，并且不能和训练增强混淆。

B4. 检查 repeat-unit SMILES 的方向等价问题

例如：

```
[*]CCO[*]
[*]OCC[*]
```

可能代表相同或等价的重复结构，但普通字符串比较可能将其视为不同样本。

需要检查：

- 连接点标签是否统一；
- 两个端点的顺序是否统一；
- 正向和反向遍历是否等价；
- 从重复单元不同位置开始书写是否会产生不同字符串；
- 不同周期表示是否对应同一种聚合物。

建议在补充材料中提供：

- equivalence detection 方法；
- exact duplicate 数量；
- reversed representation 数量；
- 合并前后的样本数。

B5. 增加 similarity-clustered cross-validation

GroupKFold 只能阻止完全相同结构跨 fold，但不能测试对新化学空间的泛化。

建议增加第二套验证：

验证协议1：Identity-grouped CV

目的：

- 防止完全相同聚合物泄漏；

- 作为主要结果。

验证协议2：Similarity-clustered CV

目的：

- 防止高度相似聚合物随机分散；
- 测试结构外推能力。

建议方法：

1. 对 canonical repeat units 计算 Morgan fingerprints；
2. 计算 Tanimoto similarity；
3. 进行 Butina clustering 或其他相似性聚类；
4. 以 cluster 为单位划分 folds；
5. 保证同一 cluster 不跨 fold；
6. 尽量平衡各 fold 的样本量和目标分布。

相似度阈值可以考虑：

- 0.7；
- 0.8；
- 或根据数据相似度分布选择并解释。

如果计算资源有限，至少做一种合理阈值的 clustered CV。

B6. 报告验证样本与训练集的最近邻相似度

对于每个验证聚合物：

$s_i = \max_{j \in \text{train}} \text{Tanimoto}(i, j)$

然后报告：

- mean similarity；
- median similarity；
- similarity distribution；
- 不同相似度区间的 MAE。

例如：

Subset	Maximum train similarity	Number	MAE
Low similarity	$s < 0.4$		
Medium similarity	$0.4 \leq s < 0.7$		
High similarity	$s \geq 0.7$		

这样可以直接说明：

- 模型是否只在近邻结构上表现好；
- 对新结构的性能下降多少；
- 模型更适合插值还是外推。

B7. 检查预处理泄漏

每个 fold 中以下操作都必须只在训练部分拟合：

- descriptor normalization；
- target standardization；
- missing-value imputation；
- feature selection；
- PCA；
- dimensionality reduction；
- 超参数选择；
- early stopping；
- 模型选择。

正确做法：

```
Training fold:
fit scaler → transform training data

Validation fold:
use training-fitted scaler → transform validation data
```

禁止在全部数据上先 fit scaler，再做五折交叉验证。

C. Table 1 与 Table 2 的矛盾

C1. 首先进行结果审计

重点追踪：

- 53.39 K 来自哪个代码和数据；
- 4.02 K 来自哪个代码和数据；
- 是否使用相同数据集；
- 是否使用相同 folds；
- 是否在归一化空间计算；
- 是否忘记 inverse transform；
- 是否把 RMSE、MAE 或标准化 MAE 混淆；
- 是否把训练误差写成测试误差；

- 是否使用了单次随机划分；
- 是否只使用某个子集；
- 是否存在单位问题；
- 是否存在 duplicate leakage；
- 是否为旧模型版本结果；
- 是否为录入错误。

C2. 建立内部结果追踪表

建议先在内部完成：

Result	Dataset	Split	Sample count	Unit	Scaling	Evaluation set	Code version
53.39 K				K		OOF/test	
4.02 K				K		OOF/test	

如果无法明确追溯 4.02 K 的来源，应直接删除，不要勉强解释。

C3. 统一重新生成全部结果

最终所有主要性能应来自同一流程：

- 同一清洗后数据集；
- 同一 group folds；
- 同一目标单位；
- 同一预处理；
- 同一评价代码；
- 同一 out-of-fold predictions；
- 同一统计方法。

建议同时报告：

1. pooled OOF MAE；
2. fold-level mean ± SD。

需要明确两者的定义：

$$\mathrm{MAE}_{OOF} = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

而 fold-level mean 是：

$$\overline{\mathrm{MAE}} = \frac{1}{K}\sum_{k=1}^{K}\mathrm{MAE}_k$$

两个结果可能略有不同，不能混用。

C4. 修订回复中必须说明真实原因

不能只写：

> Due to an oversight.

应该写清楚：

> The value of 4.02 K was obtained from [具体数据集/具体划分/标准化空间/旧版本结果] and was incorrectly presented as directly comparable to the five-fold cross-validation result.

如果是代码错误，需要明确说：

> The discrepancy resulted from calculating the error before inverse transformation.

如果是表格错误：

> The value was mistakenly transferred from an earlier experiment using a different dataset split.

必须如实填写，不能猜测。

D. 基线和 SOTA 比较

D1. 最理想方案：同协议重跑基线

所有模型必须使用：

- 相同数据；
- 相同 folds；
- 相同训练/验证样本；
- 相同目标定义；
- 相同评价指标；
- 相同物理单位；
- 尽量一致的超参数调优预算。

建议至少加入以下基线：

传统机器学习基线

- Morgan fingerprint + Random Forest；
- Morgan fingerprint + XGBoost；
- RDKit descriptors + Random Forest；
- RDKit descriptors + XGBoost；
- handcrafted descriptors + XGBoost。

深度学习和预训练基线

- CNN-only；

- BiLSTM-only；
- MolFormer representation；
- random-initialized encoder；
- polyBERT；
- PolyNC 或其他 polymer-specific model；
- 完整 Poly-Prophet。

D2. 公平比较表示模型的方法

为了判断预训练表示本身是否有效，建议进行：

Experiment 1：Frozen representation comparison

固定：

- 相同 folds；
- 相同 downstream regressor；
- 相同 hidden dimensions；
- 相同训练 epochs；
- 相同优化器；
- 相同超参数搜索范围。

比较：

- random initialization；
- MolFormer；
- polyBERT；
- PolyNC-compatible representation。

这样回答：

> 哪一种预训练表示包含更适合当前任务的信息？

Experiment 2：Native fine-tuning

如果计算资源允许，再分别使用各模型推荐的 fine-tuning 方式。

需要把两类结果分开，不要把 frozen 模型和 fully fine-tuned 模型当作严格公平的 representation comparison。

D3. 如果无法重跑文献模型

如果无法复现全部模型，应：

1. 删除模型性能排名；
2. 删除加粗“最佳结果”；
3. 删除提升百分比；

4. 删除“new state-of-the-art”；
5. 把表格改成定性文献总结。

例如：

Method	Representation	Dataset	Split protocol	Target	Directly comparable
Literature model A		Original dataset	Original split		No
polyBERT	Polymer language	Original dataset	Original split		No
MolFormer	Molecular language	Current dataset	Grouped CV		Yes
Poly-Prophet	Multimodal	Current dataset	Grouped CV		—

D4. 修改过强表述

建议删除或弱化：

- new state-of-the-art；
- unprecedented；
- breakthrough performance；
- dramatically superior；
- significantly outperforms，除非有显著性检验；
- universally applicable；
- highly accurate for real polymer systems。

建议替换为：

> Poly-Prophet achieved competitive performance under the structure-grouped cross-validation protocol adopted in this study.

以及：

> Because literature models were evaluated using different datasets and validation protocols, their reported metrics are not treated as directly comparable evidence of superiority.

E. 不确定性和统计分析

E1. 报告每个 fold 的结果

补充材料中增加：

Property	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Mean ± SD
T_g						
T_c						
FFV						
Density						
R_g						

E2. 主结果报告 mean ± SD

例如：

T_g $\mathrm{MAE} = 53.39 \pm 3.21$ K

不要只报告一个平均值。

同时建议报告：

- MAE；
- RMSE；
- R^2；
- 样本数 N。

其中 MAE 作为主要指标，其他指标作为补充。

E3. 增加 bootstrap confidence intervals

推荐从 out-of-fold predictions 计算95%置信区间。

建议流程：

1. 保存每个独立聚合物的真实值和 OOF prediction；
2. 以独立 polymer/group 为采样单位；
3. 有放回抽样；
4. 每次计算 MAE；
5. 重复1000–5000次；
6. 取2.5%和97.5%分位数。

报告格式：

$\mathrm{MAE} = 53.39$ K, $\quad 95\%\,\mathrm{CI} = [49.8, 57.4]$ K

不能以 augmented SMILES 为 bootstrap 单位，否则同一聚合物会被重复计算。

E4. 多随机种子实验

五折交叉验证之外，建议至少使用：

- 3个随机种子；
- 最好5个随机种子。

需要固定同一组 folds，在不同种子下改变：

- 参数初始化；
- batch 顺序；
- dropout；
- augmentation sampling。

这样可以区分：

- 数据划分波动；
- 模型训练波动。

如果计算资源有限，可把多种子实验用于完整模型和主要消融模型。

E5. 统计显著性检验

针对完整模型与主要消融模型，建议使用：

- fold-matched paired test；
- Wilcoxon signed-rank test；
- 或 paired t-test，但需要说明假设；
- 多个比较时使用 Holm correction。

同时报告：

- p-value；
- corrected p-value；
- effect size；
- ΔMAE。

注意：只有5个 folds 时统计功效有限，因此结论要谨慎。

不要只因为 MAE 相差0.1就说“显著改善”。

E6. Prediction intervals 属于加分项

如果时间和工作量允许，可以加入：

- conformal prediction；
- deep ensemble；
- Monte Carlo dropout；

- quantile regression。

建议报告：

- 90% interval coverage；
- 95% interval coverage；
- mean interval width。

但最低限度应当完成：

- 每折结果；
- mean ± SD；
- bootstrap 95% CI。

F. 消融实验

F1. 在同一 folds 下重新进行全部消融

所有消融模型必须：

- 使用完全相同的数据；
- 使用相同 folds；
- 使用相同随机种子；
- 使用相同预处理；
- 使用相同超参数预算；
- 使用相同 early-stopping 规则。

F2. 建议的消融设置

至少包括：

Model	CNN	BiLSTM	MolFormer	Handcrafted descriptors
Full model	✓	✓	✓	✓
w/o CNN	×	✓	✓	✓
w/o BiLSTM	✓	×	✓	✓
w/o MolFormer	✓	✓	×	✓
w/o descriptors	✓	✓	✓	×
MolFormer only	×	×	✓	×
Descriptor only	×	×	×	✓
CNN + BiLSTM	✓	✓	×	×

如工作量允许，增加：

- backbone descriptors only；
- side-chain descriptors only；
- no augmentation；
- random-initialized transformer；
- frozen vs fine-tuned representation。

F3. 报告变化量而不只是绝对 MAE

建议增加：

$$\Delta\mathrm{MAE} = \mathrm{MAE}_{\mathrm{ablation}} - \mathrm{MAE}_{\mathrm{full}}$$

解释：

- $\Delta\mathrm{MAE} > 0$：删除模块后性能下降；
- $\Delta\mathrm{MAE} < 0$：删除模块后性能反而改善。

建议表格：

Ablation	T_g ΔMAE	T_c ΔMAE	FFV ΔMAE	Density ΔMAE	R_g ΔMAE
w/o CNN					
w/o BiLSTM					
w/o MolFormer					
w/o descriptors					

F4. 不能选择性解释消融结果

如果出现：

- w/o CNN 的 density 更好；
- w/o MolFormer 与完整模型没有显著差异；
- descriptor-only 已经达到接近完整模型的结果；

必须如实讨论。

例如：

> Removing the CNN slightly improved density prediction, although the difference was within the fold-to-fold variability. Therefore, the present results do not establish a consistent benefit of the CNN module for density.

如果差异确实显著：

> The CNN component may introduce redundant or noisy sequence-local information for density prediction.

不要继续声称：

> Every component consistently improves all five properties.

G. MolFormer 领域差异

G1. 增加 polymer-specific baseline

最低限度建议加入：

- polyBERT。

如果资源允许，再加入：

- PolyNC；
- TransPolymer；
- 其他适合 repeat-unit/polymer representations 的模型。

G2. 增加 random initialization control

比较：

1. Randomly initialized encoder；
2. MolFormer pretrained encoder；
3. Polymer-specific pretrained encoder。

这样才能回答：

- 预训练是否有效；
- 通用分子预训练是否有效；
- 聚合物预训练是否更有效。

G3. 使用相同下游回归头进行公平比较

建议统一：

- embedding pooling；
- hidden layer；
- dropout；
- optimizer；
- learning rate search；
- training epochs；
- folds；
- seed。

如果 embedding 维度不同，可以使用一个线性 projection 层统一维度，但要对所有模型使用同样原则。

G4. 修改对 MolFormer 的结论

如果 MolFormer 优于随机初始化，但不优于 polymer-specific model：

> General molecular pretraining provides transferable information, while polymer-specific pretraining offers additional benefits for the present tasks.

如果差异不显著：

> The observed numerical benefit of MolFormer was within cross-validation variability and should not be interpreted as conclusive evidence of superior transferability.

如果 MolFormer 表现最好：

> MolFormer transferred effectively to the current repeat-unit benchmark, although this result does not eliminate the general domain mismatch between small-molecule pretraining and polymer systems.

H. 物理信息缺失与模型适用范围

H1. 增加明确的 Limitations 小节

建议讨论以下缺失变量：

聚合物结构层面

- molecular weight；
- molecular-weight distribution；
- degree of polymerization；
- tacticity；
- branching；
- crosslink density；
- copolymer sequence；
- end groups。

形态和多尺度结构

- crystallinity；
- amorphous/crystalline fraction；
- chain orientation；
- entanglement；
- chain conformation；
- interchain packing；
- free-volume distribution；
- defects。

测量和加工条件

- temperature；
- pressure；
- solvent；
- heating/cooling rate；
- thermal history；
- processing history；
- simulation box size；
- force field；
- experimental protocol。

H2. 对不同目标性质分别解释局限

T_g

受到以下因素影响：

- 分子量；
- tacticity；
- 支化和交联；
- 加热速率；
- 热历史；
- 测量方法。

热导率或相关传输性质

受到以下因素影响：

- 链取向；
- 结晶度；
- 链间堆积；
- 温度；
- 缺陷；
- 形态。

Density 和 FFV

受到以下因素影响：

- 温度和压力；
- 结晶度；
- 堆积历史；

- 链构象；
- 自由体积分布。

R_g

尤其依赖：

- 链长度；
- 分子量；
- 聚合度；
- 溶剂；
- 温度；
- 构象系综；
- 模拟条件。

如果 R_g 只根据重复单元预测，必须说明数据集中链长是否固定。如果链长不固定而模型又没有输入链长，这是一个明显限制。

H3. 限制模型的应用声明

建议加入：

> The current framework predicts dataset-conditioned property values from repeat-unit chemistry under the assumptions and conditions represented in the benchmark. It does not explicitly account for molecular weight, morphology, processing history, or experimental conditions.

再加入：

> The model is therefore more appropriate for relative screening within a chemical domain similar to the training set than for direct prediction of arbitrary bulk-polymer properties under uncontrolled conditions.

H4. 说明不可约误差

建议写：

> Polymers sharing the same repeat-unit representation may exhibit different macroscopic properties because of differences in molecular weight, tacticity, crystallinity, chain architecture, morphology, and processing history. Since these variables are absent from the input, their effects constitute an irreducible source of uncertainty for the current framework.

I. 文献部分

I1. 可考虑引用的文章

导电聚合物生物电极文章

适合放在：

- Introduction；
- functional polymer applications；
- 多尺度结构影响材料性能的讨论。

不能用作：

- ML baseline；
- polymer property prediction model；
- SOTA 对照。

HTPB 固体推进剂蠕变文章

适合放在：

- Limitations；
- 宏观性能受加载条件、界面和介观结构影响；
- repeat-unit representation 不足的讨论。

同样不能用来支持模型性能。

I2. 不建议强行引用的文章

geopolymer-stabilized recycled aggregate 文章主要涉及：

- 无机地聚合物；
- 建筑材料；
- 再生骨料；
- 离散元分析；
- 介观破坏行为。

和分子级 polymer SMILES property prediction 联系较弱。

可以在回复信中礼貌说明：

> We carefully evaluated the suggested reference. Because it focuses on discrete-element modeling of geopolymer-stabilized recycled aggregates rather than molecular representations or organic-polymer property prediction, we did not include it in order to maintain the focus of the literature review.

四、需要新增或修改的表格和图片

主文建议保留或新增

Figure 1：完整数据与验证流程

内容：

```
Raw datasets
→ structure standardization
→ duplicate resolution
→ dataset merging
→ polymer grouping
→ grouped cross-validation
→ training-only augmentation
→ prediction
→ OOF evaluation
```

Table 1：最终数据集组成

包含：

- unique polymers；
- property-specific label counts；
- target range；
- mean/std；
- missing values。

Table 2：统一验证协议下的模型性能

包含：

- OOF MAE；
- mean ± SD；
- RMSE；
- R^2；
- 95% CI。

Table 3：公平基线比较

只放同数据、同 folds、同指标的结果。

Table 4：消融实验

包括：

- mean ± SD；
- ΔMAE；
- corrected p-value。

Figure 2：Parity plots

每个性质提供：

- measured vs predicted；
- identity line；

- OOF predictions；
- 最好标记 train-neighbor similarity 或 uncertainty。

Figure 3：误差与结构相似度关系

- nearest-neighbor similarity distribution；
- MAE vs similarity；
- low/medium/high similarity 子集表现。

补充材料建议增加

Table S1

每个数据源的原始数据审计。

Table S2

primary 与 supplementary datasets 的重叠情况。

Table S3

五个 folds 中的样本数和目标分布。

Table S4

每折性能。

Table S5

不同随机种子的结果。

Table S6

完整消融结果。

Table S7

超参数和搜索范围。

Table S8

数据清洗和排除记录统计。

Figure S1

五个性质标签的 UpSet plot。

Figure S2

目标性质分布。

Figure S3

结构相似度分布。

Figure S4

bootstrap MAE distribution。

五、论文各章节怎么改

1. Abstract

需要修改：

- 删除未经统一 benchmark 支持的 SOTA 声明；
- 删除不可信的巨大提升百分比；
- 写明使用 structure-grouped CV；
- 给出修正后的真实性能；
- 简要提及模型适合 screening，而不是替代实验。

推荐表述：

> Under structure-grouped five-fold cross-validation, Poly-Prophet achieved competitive predictive performance across the evaluated polymer properties. Similarity-clustered evaluation further revealed the expected performance decrease for structurally novel polymers, highlighting the distinction between interpolation and chemical-space extrapolation.

---

2. Introduction

需要修改：

- 更明确地说明现有 polymer representation 的挑战；
- 加入 small-molecule-to-polymer domain mismatch；
- 不要在引言中过早宣称 SOTA；
- 加入重复单元不能完整描述宏观聚合物性质的问题；
- 合理加入审稿人建议的相关文献。

---

3. Dataset/Methods

这是修改最多的部分，必须增加：

- 每个数据源的规模；
- 数据融合规则；
- canonicalization；
- duplicate detection；

- repeat-unit equivalence；
- label conflict handling；
- group ID；
- fold generation；
- training-only augmentation；
- train-only preprocessing；
- hyperparameter tuning；
- random seeds；
- OOF prediction generation；
- confidence interval 方法；
- statistical test 方法。

---

4. Results

需要修改：

- 所有数值统一重新生成；
- 主表报告 mean ± SD；
- 增加 CI；
- 区分 grouped CV 和 similarity-clustered CV；
- 只在统一协议下比较基线；
- 重新解释 ablation；
- 诚实报告表现变差或不显著的模块；
- 删除与当前协议不一致的 Table 2 数值。

---

5. Discussion

建议重点讨论：

- 插值和外推的区别；
- 结构相似度对性能的影响；
- MolFormer 的迁移价值和领域局限；
- polymer-specific representations 的表现；
- 不同模块对不同性质的贡献并不一定相同；
- 数据异质性和标签噪声；
- 缺失物理变量导致的误差下限。

---

6. Limitations

建议单独设立小节，集中讨论：

- repeat-unit-only representation；
- 分子量和聚合度缺失；
- 三维构象和形态缺失；
- 实验/模拟条件缺失；
- 数据来源异质性；
- 高相似度样本可能使随机划分结果偏乐观；
- 模型适用域；
- prediction uncertainty。

---

7. Conclusion

不能再写：

> Poly-Prophet establishes a new state-of-the-art for universal polymer property prediction.

建议改成：

> Poly-Prophet provides a multimodal framework for learning complementary information from repeat-unit sequences, pretrained representations, and explicit structural descriptors. Under leakage-controlled validation, the framework achieved competitive performance, although its applicability remains conditioned on the chemical domain and physical information represented in the training data.

六、建议的实际执行顺序

为了避免反复修改，建议按以下顺序操作。

第一阶段：数据审计

1. 整理所有原始数据文件；
2. 给每条记录添加 source ID；
3. 统一单位；
4. 解析 SMILES；
5. 标准化重复单元；
6. 生成 canonical polymer identity；
7. 检查重复和方向等价结构；
8. 统计 primary/supplementary overlap；
9. 处理冲突标签；
10. 生成最终 master dataset。

第二阶段：重新划分数据

1. 分配 polymer group ID；
2. 建立 grouped five-fold splits；

3. 建立 similarity-clustered folds；
4. 保存每个 fold 的样本 ID；
5. 检查任何 group 是否跨 fold；
6. 检查各 fold 的目标分布。

第三阶段：重新训练

1. 只在训练 fold 拟合 scaler；
2. 只增强训练 fold；
3. 重新训练完整模型；
4. 重新训练传统基线；
5. 重新训练消融模型；
6. 运行 polymer-specific baseline；
7. 至少进行3个随机种子。

第四阶段：重新评价

1. 生成 OOF predictions；
2. inverse transform；
3. 计算 MAE、RMSE、R^2；
4. 计算每折结果；
5. 计算 mean ± SD；
6. 计算 bootstrap 95% CI；
7. 计算 ΔMAE；
8. 进行 paired statistical tests；
9. 分析 error vs similarity。

第五阶段：重新写论文

1. 更新 Methods；
2. 替换所有表格；
3. 更新图；
4. 重写 Results；
5. 重写 Discussion；
6. 增加 Limitations；
7. 修改 Abstract 和 Conclusion；
8. 删除或弱化 SOTA 声明；
9. 最后撰写逐条回复信。

七、最终 Checklist

下面可以直接作为修稿任务清单使用。

A. 数据集审计

- 统计每个数据源的 raw rows
- 统计 valid/invalid SMILES
- 统计 canonicalization 后的 unique polymers
- 统计重复结构数量
- 统计每个目标性质的有效标签数量
- 统计每个目标性质的缺失标签数量
- 统计 primary 与 supplementary datasets 的重叠数量
- 说明重叠结构如何处理
- 说明冲突标签如何处理
- 统一目标单位
- 区分 raw records、unique polymers 和 augmented sequences
- 增加 dataset composition table
- 增加标签重叠 UpSet plot
- 明确是一个多任务模型还是五个单任务模型

B. 结构标准化与重复识别

- 标准化 repeat-unit SMILES
- 标准化连接点标签
- 检查正向/反向重复单元等价性
- 检查不同周期写法是否代表同一聚合物
- 生成稳定的 polymer group ID
- 将跨数据源的相同聚合物归入同一 group
- 记录合并和删除的样本数

C. 数据泄漏控制

- 在 augmentation 前完成数据划分
- 使用 GroupKFold 或等价方法
- 确保同一聚合物不跨 fold
- 确保不同 SMILES 表示不跨 fold
- 确保 supplementary overlap 不跨 fold
- 只对训练 fold 进行 SMILES augmentation
- 验证集使用非增强表示

- scaler 只在训练 fold 拟合
- imputation 只在训练 fold 拟合
- feature selection 只在训练 fold 进行
- 超参数调优不使用外部验证 fold
- 保存并检查 fold IDs
- 提供 no-overlap 检查结果

D. 泛化验证

- 完成 identity-grouped five-fold CV
- 完成 similarity-clustered CV
- 说明 fingerprint 类型
- 说明 Tanimoto threshold
- 说明聚类算法
- 报告每个 fold 的样本量
- 报告 validation-to-training nearest-neighbor similarity
- 报告不同相似度区间的 MAE
- 讨论 interpolation 与 extrapolation 的差异

E. Table 1/Table 2 数值审计

- 确认 53.39 K 的来源
- 确认 4.02 K 的来源
- 检查数据集是否相同
- 检查 split 是否相同
- 检查单位是否相同
- 检查是否遗漏 inverse transformation
- 检查是否误用训练集结果
- 检查 MAE/RMSE 是否混淆
- 检查是否为旧实验结果
- 无法复现的结果全部删除
- 统一重新生成 OOF predictions
- 统一重新计算所有性能指标
- 在回复信中说明真实错误原因

F. 基线比较

- Morgan fingerprint + RF/XGBoost
- RDKit descriptors + RF/XGBoost
- Handcrafted descriptors-only baseline

- CNN-only baseline
- BiLSTM-only baseline
- MolFormer baseline
- Random-initialized encoder baseline
- polyBERT baseline
- PolyNC/TransPolymer baseline，如条件允许
- 所有基线使用相同 folds
- 所有基线使用相同评价指标
- 所有基线在原始物理单位下评价
- 公平控制超参数调优预算
- 将文献结果标记为是否直接可比

G. 不确定性与统计分析

- 报告每个 fold 的 MAE
- 报告 mean ± SD
- 报告 pooled OOF MAE
- 报告 RMSE
- 报告 R^2
- 报告样本量 N
- 计算 bootstrap 95% CI
- bootstrap 以 polymer/group 为单位
- 运行至少3个随机种子
- 对主要消融进行 paired test
- 对多重比较进行 Holm correction
- 报告 effect size 或 ΔMAE
- 避免把数值差异直接描述成统计显著

H. 消融实验

- 完整模型
- w/o CNN
- w/o BiLSTM
- w/o MolFormer
- w/o handcrafted descriptors
- MolFormer only
- Descriptor only
- CNN + BiLSTM only
- no augmentation，如条件允许

- 所有消融使用相同 folds
- 所有消融使用相同 seeds
- 报告 mean ± SD
- 报告 ΔMAE
- 报告统计检验结果
- 解释删除模块后性能改善的情况
- 删除"所有模块均对所有性质有效"的绝对表述

I. MolFormer 与领域迁移

- 比较随机初始化与预训练 MolFormer
- 加入至少一个 polymer-specific representation
- frozen representations 使用相同回归头
- 使用相同 folds 和超参数范围
- 区分 frozen comparison 和 native fine-tuning
- 根据实际结果重写 MolFormer 相关结论
- 不再把通用分子预训练默认解释为最优聚合物表示

J. 物理局限和应用范围

- 讨论 molecular weight 缺失
- 讨论 degree of polymerization 缺失
- 讨论 molecular-weight distribution 缺失
- 讨论 tacticity 缺失
- 讨论 branching/crosslinking 缺失
- 讨论 crystallinity 缺失
- 讨论 entanglement 缺失
- 讨论 chain conformation 缺失
- 讨论 3D packing 缺失
- 讨论 processing history 缺失
- 讨论实验/模拟条件缺失
- 重点解释 R_g 对链长的依赖
- 增加独立 Limitations 小节
- 将模型定位为相似化学域内的快速筛选工具
- 避免声称模型能够替代实验

K. 文献修改

- 检查审稿人推荐的三篇文章
- 在合适位置引用导电聚合物文章

- 在 limitations 中酌情引用 HTPB 文章
- 不把上述文章当作 ML baseline
- 对不相关的 geopolymer 文章进行礼貌说明
- 补充 polymer-specific representation 文献
- 补充 structure-aware splitting 相关文献
- 补充 uncertainty quantification 相关文献

L. 论文文字和结论

- 删除未经公平 benchmark 支持的“new SOTA”
- 删除“unprecedented”
- 删除“breakthrough margins”
- 删除不可靠的提升百分比
- 将“significantly”限定于有统计检验的结果
- Abstract 中写明 grouped CV
- Methods 中完整说明防泄漏流程
- Results 中报告 fold variability
- Discussion 中区分插值和外推
- 增加 Limitations
- Conclusion 中限制模型适用范围
- 全文统一数据量、单位和表格数值
- 检查正文、表格、补充材料是否一致

M. 可复现性材料

- 提供清洗后的 polymer IDs
- 提供 source IDs
- 提供 fold assignments
- 提供 group IDs
- 提供 cluster IDs
- 提供 out-of-fold predictions
- 提供 metric calculation code
- 提供 preprocessing code
- 提供 random seeds
- 提供超参数表
- 提供软件版本
- 提供数据排除和合并记录

N. 回复信

- 每条审稿意见单独引用
- 每条回复先表示感谢
- 明确说明做了什么修改
- 提供修改后的具体结果
- 标出页码、行号、表格或图号
- 对无法完成的实验说明客观原因
- 不回避 Table 1/Table 2 的错误
- 不使用“due to an oversight”代替具体解释
- 两位审稿人的共同问题使用相同实验结果回复
- 保持回复信与修订稿数值完全一致

八、最低限度必须完成的项目

如果时间和计算资源有限，以下内容是不能省略的：

1. 数据集组成和每个性质的样本量；
2. primary/supplementary overlap；
3. canonical polymer identity 去重；
4. group-level five-fold cross-validation；
5. augmentation 只能用于训练 fold；
6. 审计并解决 53.39 K 与 4.02 K 的矛盾；
7. 所有结果统一重新计算；
8. 主表增加 mean ± SD；
9. 增加 bootstrap 95% CI；
10. 在相同 folds 下重新运行主要消融；
11. 删除或弱化 SOTA 声明；
12. 解释不符合预期的 ablation；
13. 加入至少一个 polymer-specific baseline；
14. 增加 repeat-unit representation 的限制；
15. 明确模型的实际应用范围。

九、最终建议的论文定位

修改后，文章不应再以“巨大幅度刷新所有性质的 SOTA”为核心。

更稳妥、也更容易得到审稿人认可的定位是：

> 本文提出了一种融合序列局部特征、长程依赖、预训练分子表示以及显式骨架/侧链描述符的聚合物性质预测框架。在严格控制结构重复、SMILES 增强和数据源重叠所导致的数据泄漏后，该框架在多个聚合物性质上表现出具有竞争力的预测性能。消融和结构相似度分析进一步表明，不同表示模块对不同性质具有互补但非完全一致的贡献，同时模型对结构新颖聚合物的外推能力仍受到数据规模和重复单元表示的限制。

这个定位能够同时回应两个审稿人的主要问题，而且比单纯强调 SOTA 更可靠。